

Previsão de Demanda de Estoque

Como a Ciência de Dados Pode Transformar a Gestão Operacional

Autor:

Lenildo Isaias da Silva (lenildolims15@gmail.com).

Resumo

Gerenciar estoques de forma eficiente é um dos grandes desafios do varejo. Este projeto foca em prever demandas futuras com base em dados reais do varejo, utilizando a metodologia CRISP-DM. Nosso objetivo é oferecer soluções que ajudem a reduzir custos, evitar rupturas de estoque e melhorar a satisfação do cliente. Aplicamos algoritmos como Random Forest para criar um modelo preditivo robusto, priorizando semanas críticas, como feriados. Além disso, o projeto destaca os benefícios estratégicos de decisões baseadas em dados para áreas como compras e marketing.

Introdução

Gerenciar projetos de ciência de dados pode ser complicado, especialmente quando se trata de aplicar processos estruturados. No mundo real, muitas empresas ainda não seguem metodologias claras, o que dificulta alcançar bons resultados.

Este projeto explora como a metodologia CRISP-DM pode ser aplicada em um cenário prático: prever a demanda de estoque para o varejo. Usamos dados reais de vendas do Walmart uma multinacional de varejo que opera lojas de departamento, hipermercados e mercearias, além da rede Sam's Club, que são ricos em detalhes como sazonalidade, promoções e condições econômicas. Nosso foco está em fornecer insights úteis para o varejo, respondendo a perguntas como:

- **O que está acontecendo?** (feedback descritivo)
- **Por que isso está acontecendo?** (diagnóstico)
- **O que pode acontecer?** (preditivo)
- **O que fazer a partir disso?** (prescritivo).

Entendimento do Negócio

Para qualquer varejista, estoque é dinheiro. Ter muito significa custos altos e risco de perdas; ter pouco pode frustrar clientes e levar à perda de vendas. Nosso objetivo é claro: prever a demanda com maior precisão para ajudar na tomada de decisões estratégicas.

Principais ações do projeto:

- Entender os recursos disponíveis e definir metas claras.
- Desenvolver um plano detalhado com cronograma, orçamento e ferramentas necessárias.
- Avaliar os impactos potenciais de uma solução, como reduzir custos de armazenagem e melhorar o atendimento ao cliente.

Perguntas que orientaram este trabalho:

1. Qual problema queremos resolver? (**Previsões imprecisas de estoque**)
2. Por que isso é importante? (**Impacta diretamente os lucros e a experiência do cliente**)
3. Como mediremos o sucesso? (**Redução de custos, aumento na precisão e na disponibilidade de produtos**)

Entendimento dos Dados

Os dados utilizados vieram da base de dados do *Walmart disponível no Kaggle*, contendo vendas semanais, feriados, condições climáticas e indicadores econômicos. Isso nos permitiu compreender o comportamento de consumo em diferentes períodos e fatores que influenciam as vendas.

Pontos principais observados nos dados:

- Alta sazonalidade: picos de vendas em feriados, como Black Friday e Natal.
- Correlações significativas: feriados impactam fortemente a demanda.
- Dados limpos e consistentes, mas com alguns valores ausentes tratados por imputação.

Preparação dos Dados

Antes de alimentar os modelos, fizemos ajustes para garantir que os dados estivessem prontos:

- Variáveis categóricas foram transformadas em números com *One-Hot Encoding*.
- Aplicamos técnicas de escalonamento para alinhar os valores em uma mesma escala.
- Outliers foram analisados cuidadosamente, mantendo aqueles que refletiam picos reais, como feriados 3.

Modelagem

Escolha do modelo: Testamos várias opções, como Regressão Linear, XGBoost e Redes Neurais, mas o **Random Forest** foi o mais adequado por capturar relações complexas entre variáveis e lidar bem com dados ruidosos.

Resultados:

- **WMAE** (Erro Ponderado): excelente precisão em semanas críticas.
- **R²** (Coeficiente de Determinação): 0.88, indicando uma explicação robusta da variabilidade nos dados.

Através do modelo, aprendemos que variáveis como feriados e tipo de loja têm o maior impacto nas vendas 3.

Implantação

O modelo foi implementado em Python, usando bibliotecas como Pandas, Scikit-learn e TensorFlow, com infraestrutura local (desktop) para validação.

Passos para acesso e uso da solução:

- Monitoramento contínuo para ajuste do modelo com mudanças no mercado.
- Integração com sistemas operacionais para automação das previsões.

Considerações Finais

Este projeto demonstrou como a ciência de dados, aliada ao CRISP-DM, pode transformar a gestão de estoques no varejo. Conseguimos atender aos principais objetivos, mesmo com desafios como a falta de variáveis externas.

Sugestões futuras:

- Incluir mais dados externos, como promoções e tendências econômicas.
- Explorar modelos híbridos para combinar os pontos fortes de diferentes algoritmos.

A previsão de estoque não é apenas uma solução técnica, mas uma forma de garantir que as empresas atendam melhor seus clientes e se mantenham competitivas no mercado.

Referências

1. KAGGLE. *Walmart Dataset*. Disponível em: [kaggle.com](https://www.kaggle.com/datasets/walmart-inc/walmart-dataset). Acesso em 03 dez. 2024.

Código do projeto e banco de dados do projeto.

<https://github.com/Dark1zin/Previsoes-Walmart>